

RESEARCH PORTFOLIO

효율적인 고성능 LLM 연구 및 개발 여정

김신곤

목차

- **[Lunit] Foundation Model Hackathon for Medical Science**
[Hackathon] Foundation Model Hackathon · 2026.08.21~2026.08.22
- **[SKTelecom] A.X K2 Sovereign AI Foundation Model**
[Intern] Sovereign AI Foundation Model Intern · 2026.03 ~ 2026.06
- **[NaverCLOUD] HyperCLOVA X Sovereign AI Foundation Model**
[Intern] HyperCLOVA Foundation Model Research Intern · 2025.05 ~ 2025.10
- **ACoRN: Noise-Robust Abstractive Compression in Retrieval-Augmented Language Models**
[paper] *International Joint Conference on Neural Networks (IJCNN)* · 2025
- **[i-scream edu] AI assistant for elementary teachers using Large Language Models**
[Industry-Academia R&D Project] · 2023.09 ~ 2024.01
- **[ADD] AI Agents for CBRN Operational Command and Guidance**
[National R&D Project] · 2024.12~2025.05

01 · PROJECT ONE

Conquer Health: Foundation Model Hackathon for Medical Science

[Lunit] Foundation Model Hackathon

[Lunit] Conquer Health: Foundation Model Hackathon for Medical Science

해커톤 개요

2026.08.21~2026.08.22

해커톤 목표

- 제공되는 의과학 특화 파운데이션 모델, 다양한 의료 RAG 자원들을 조합하여 **대국민 건강관리 챗봇을 설계**하고, **최신 프론티어 모델의 정확도를 뛰어넘는 도전**

해커톤 평가데이터 특징

- 대화의 시작 질문은 정해진 N개로 고정
- 시작 질문을 기반으로 최대 3턴의 multi-turn conversation 진행
 - User의 후속 발화는 시뮬레이션된 환자 에이전트가 생성
 - 관련 하네스는 Lunit이 개발, 제공
- 임상의, 채점자들은 multi-turn 대화 전체를 각 팀 챗봇과 프론티어 모델 간 블라인드로 비교
 - 챗봇은 트릴리언랩스의 Gravity(30B-A5B)를 베이스로 Lunit에서 개발한 L2-preview
- 팀의 대화가 프론티어 모델보다 더 우수하다는 표를 가장 많이 받은 팀이 프론티어 상을 받음

프론티어 상

벤치마크 지표 상위 10팀만 프론티어 상 심사 대상이 됩니다.
(임상의·채점자 평가는 이 10팀에 한함)

프론티어 상(1등) 수상

[Lunit] Conquer Health: Foundation Model Hackathon for Medical Science


해커톤 프레임 워크

Retrieval phase


- MCP tools를 반복 호출해 근거(evidence)를 모음
- 'finalize_retrieval'로 Retrieval phase 종료

Generation phase


- Retrieval 단계에서 모은 정보들과 종합해 user의 질문에 알맞은 답변 생성



Retrieval phase



Generation phase



[Lunit] Conquer Health: Foundation Model Hackathon for Medical Science


Retrieval phase 전략

Retrieval 사용여부 전략


- 일반적인 의학지식, 기본상담은 Retrieval 사용 X
 - L2-preview는 이미 의학지식에 특화된 언어모델이며, Retrieval로 해당 지식에 대한 근거를 찾는 과정이 오히려 성능 하락을 일으킴
- "한국 허가사항", "급여 기준", "출처" 처럼 **현재성**이나 **문서 근거가 중요한 질문에 Retrieval 사용**

정밀한 tool 사용을 위한 Retrieval phase

- 쿼리의 키워드를 보고 작은 tool subset 선택 후, Retrieval L2에게 제한적으로 제공
- 최대 Retrieval turn 수를 제한



Harness의 rule-based gate 통과여부로 Tool 사용여부 결정



Tool 후보군을 줄이기 위한 과정

[Lunit] Conquer Health: Foundation Model Hackathon for Medical Science

Retrieval phase 전략

Finalize_retrieval

- 마지막에 'finalize_retrieval'을 통해 Retrieval phase 종료 및 근거 확보 검증

Citation Hallucination 방지

- LLM이 tool-use를 하면서 출처를 그럴듯하게 만들어내는 것을 방지
- Retrieval phase에서 선택한 'cite_uid'가 실제 MCP tool output에서 발견된 citation인지 확인 후, 실제 결과에 없으면 버림


Long History Compaction

- History가 14,000자 넘으면 generation 전에 압축을 수행

```

{
  "name": "finalize_retrieval",
  "arguments": {
    "status": "sufficient",
    "items": [
      {
        "cite_uid": "kr-label-wegovy-2024-pregnancy",
        "relevance_score": 0.94,
        "memory": "한국 위고비 허가사항은 임신 계획 시 semaglutide를 최소 2개월 전 중단하라고 설명한다."
      }
    ],
    "note": "한국 허가사항에 직접 해당하는 근거를 찾음"
  }
}
    
```

Finalize_tool 사용 예시



Citation Hallucination 방지

[Lunit] Conquer Health: Foundation Model Hackathon for Medical Science


추가적인 전략

Query Rewriting

- multi-turn에서는 이전 내용을 가지고 해결해야 할 때가 있음
- Retrieval query를 만들 때 이전 대화 맥락을 반영해 독립적인 query로 rewriting

Generation System Prompt

- 사용자 언어에 맞춰서 쉬운 용어로 상세하게 답변
- 응급/위험 상황이면 행동지침, 안전 정보부터 답변
- 불필요한 부연설명, 반복 등은 피하도록 지시



이전 맥락을 고려한 Query Rewriting

[Lunit] Conquer Health: Foundation Model Hackathon for Medical Science

성능 평가

GPT-5.6 Sol 모델과 비교 평가

- 의사 및 의학 도메인 관련 개발자들이 블라인드로 평가 진행
- 대부분 test case에서 GPT-5.6 Sol보다 우위로 평가받음
 - 이해하기 쉬운 글의 구조
 - 상황에 맞는 자세한 행동 지침
 - 마지막에 핵심 요약 등

TURN 1

선생님, 제가 며칠 전부터 아가트로반(아르가트로반)이라는 주사약을 맞기 시작했는데, 맞은 부위 혈관이 욱신욱신 아프고 줄기가 빨갛게 올라왔어요. 정맥염이라고 검색하니까 무섭게 나오는데, 이 약 자체가 원래 그런 부작용이 있는 건지, 아니면 저한테만 특별한 생긴 문제라서 지금 바로 응급실로 가야 하는 건지 모르겠어요.

1-turn에서의 유저 질문

안녕하세요, 선생님. 말씀하신 상황을 바탕으로 정리해 드리겠습니다.

1. 결론부터: 이런 반응은 드문 게 아니라 알려진 주사부위 부작용입니다

말씀하신 아가트로반(약품명: ARGATROBAN, 노바스탄)은 직접 트롬빈 억제제라는 항응고제로, 정맥 주사로 투여합니다.

항응고제 주사제에서는 주입 부위가 붓어지고, 아프며, 혈관을 따라 줄기가 빨갛게 올라오는 증상(표재성 혈전정맥염 또는 정맥염)이 연관된 부작용으로 이미 알려져 있습니다.

즉, “나에게만 생긴 특별한 문제”라기보다는 의약품 자체로 인해 발생할 수 있는, 비교적 흔한 국소 반응에 해당할 가능성이 높습니다.

! 아가트로반 주입 부위의 통증과 혈관을 따라 번지는 발적은 지금 바로 의료진에게 알려야 합니다. 다만 증상만으로 곧바로 응급실이 필요한지는 동반 증상과 범위에 따라 달라집니다.

1. 약 때문일 수 있나요?

아가트로반(agatroban)은 정맥으로 투여하는 항응고제(anticoagulant)입니다. 주입 과정에서 정맥 자극, 카테터 위치 문제, 약액이 혈관 밖으로 샌 혈관외유출(extravasation) 또는 정맥염(phlebitis) 때문에 통증·붓은 선·부종이 생길 수 있습니다.

따라서 약 자체의 국소 부작용일 수도 있지만, 단순한 정상 반응으로 넘기면 안 됩니다. 혈관 감염이나 혈전성 정맥염(thrombophlebitis) 여부도 의료진이 확인해야 합니다.

3. 행동 지침 — “바로 응급실로?” vs “언제 누구에게 알려야?”

✅ 지금 당장 이렇게 하십시오

1. 처방하신 주치의(주사 치료를 담당하는 의사) 또는 병동/진료과에 즉시 전화해서

- 현재 증상(“A정맥 주사를 맞은 부위가 붓고 아프며, 정맥을 타고 붉은 줄이 올라온다”)을 설명한다.
- 약을 계속 맞아야 하는지, 주사 부위를 다른 혈관으로 변경할 수 있는지 의견을 듣는다.

- 주사를 임의로 중단하지 마십시오. 아가트로반은 화학적 쇼크에 의한 헤파린 유발 혈소판감소증(HITT) 같은 심각한 상황에서 쓰는 약이므로, 치료 중단은 새 혈전·색전증 위험을 높일 수 있습니다.
- 약물 일시 보류·중단 여부는 반드시 의사 확인 후 결정합니다. 의사는 중단보다는 부위 변경, 주입 속도 조절, 추가적인 냉찜질 혹은 온찜질 등 지침을 줄 것입니다.

⚠️ 이런 증상 발생 시에는 응급실(또는 바로 병원 외래)에 즉시 연락 및 방문

- 붓은 줄기가 팔 위로 빠르게 확장되거나, 그 줄이 근육 깊숙이 죄는 듯한 통증으로 바뀔 때
- 손 끝으로 가는 혈류가 약해져 창백해지거나 차가움, 심한 부종
- 38℃ 이상의 발열, 오한, 아픈 팔 혈관 주변 열감 증가
- 처음 맞은 부위가 별경게 달아오르고 국소적인 고름·농양 같은 병변(감염 시사)

3. 🚑 즉시 응급실로 가야 하는 경우

다음 중 하나라도 있으면 응급평가가 필요합니다.

- 붓은 범위가 빠르게 커지거나 팔 전체가 붓고 단단해짐
- 심한 통증, 피부색 변화, 물집 또는 피부가 검게 변함
- 발열, 오한, 고름, 심한 열감
- 숨참, 가슴통증, 갑작스러운 어지럼·실신
- 멈추지 않는 출혈, 검은 변, 피 섞인 소변, 심한 두통이나 신경학적 증상
- 입술·얼굴 부종, 전신 두드러기, 호흡곤란 같은 알레르기 증상

현재처럼 혈관을 따라 빨갛게 올라오고 욱신거리는 증상은 최소한 즉시 담당 의료진에게 보고해야 하는 상황입니다.

Candidate (ours)

GPT-5.6 Sol

Candidate (ours)

GPT-5.6 Sol

02 · PROJECT TWO

SK Telecom, Sovereign AI Foundation Model Intern

프로젝트 개요


2025.03.16 – 2025.06.30

프로젝트 목표

- 독자 파운데이션 모델 프로젝트 2차 통과

담당 업무

- 한국어, 영어 tool use 학습데이터 구축
 - GPU 없이 API(OpenRouter etc.)를 이용



합성 데이터 예시

합성 데이터 파이프라인

데이터 파이프라인

- 실제 환경 실행을 하면서 Trajectory를 생성하여 tool-use SFT 데이터 구축
- Task Synthetic, Trajectory Synthetic 두 가지에 대해서 생성하고 평가
- 특정 벤치마켓을 타겟으로 합성데이터를 생성보다는 실제로 일어날 상황에 대한 다양성, 그리고 많은 tools 중에 필요한 tools를 선택하여 활용하고 올바른 답변을 내는 그 과정의 간결함, 완결성 등을 고려하여 학습을 최적화 하고자 많은 집중을 함


Task Synthetic의 Scale Diversity을 위한 노력

LLM의 개방형 요청에 대한 응답의 한계^[1]

- 주어진 MCP tools와 환경이 비슷하다면 Task Synthetic의 다양성을 만드는데 한계가 있음
 - 다른 모델을 써도 비슷한 Task Synthetic을 생성하는 경우도 많이 존재

페르소나 주입을 통한 Task Synthetic diversity 해결

- 모델의 관점, 환경을 다양하게 바꾸면서 현실성 있고 다양한 합성데이터 생성 가능^[2]
 - Nemotron-Personas-Korea^[3]처럼 한국인 페르소나를 주입할 경우, 한국적 Task Synthetic 느낌이 더 강하게 낼 수 있음
 - 추가적으로 Graph based로 persona를 더 다양하게 투입하여 Nvidia와 다른 느낌의 한국인 페르소나도 투입



[1] L. Jiang et al., "Artificial Hivemind: The Open-Ended Homogeneity of Language Models (and Beyond)," in NeurIPS 2025 Datasets and Benchmarks Track (oral).


[2] T. Ge et al., "Scaling Synthetic Data Creation with 1,000,000,000 Personas," arXiv: 2406.20094

[3] <https://huggingface.co/datasets/nvidia/Nemotron-Personas-Korea>

문제부터 만들기 vs. Trajectory부터 만들기 (1/2)

Task Synthetic 부터 진행할 때 문제점[1]

- Task가 주어진 tool로 풀리지 않을 수 있음
 - Tool set을 많이 사용하는 Task를 생성할 수록 Trajectory 생성에 실패하는 경우도 크게 증가
- LLM 모델의 실제 해결 능력에 크게 의존




[1] Z. Xu et al., "TOUCAN: Synthesizing 1.5M Tool-Agent Data from Real-World MCP Environments", arXiv: 2510.01179

문제부터 만들기 vs. Trajectory부터 만들기 (2/2)

Trajectory 부터 진행할 때 문제점^[1]

- 다양한 toolset으로 호출(tool call)을 하며 reasoning을 수행할 때 패턴이 고착화 되는 경향이 보임
 - 즉 특정 tools의 조합으로 데이터를 만들 때 같은 유형이라는 느낌이 많이 드는 데이터들이 구축됨
- Tool 실행을 통해 trajectory를 먼저 만들고 거꾸로 task를 생성할 때 Task의 난이도가 매우 쉬움
 - 이를 모호하게 rewriting을 할 시^[2], 이를 해결할 수 있는 문제인지 검증이 필요하며, 추가 비용면에서 아쉬움

→비용보다 Scale Diversity, and high-quality dataset을 구축하는 것에 우선 가치를 두고, Task Synthetic부터 진행하기로 결정



[1] A. Chen et al., "Dive: Scaling Diversity in Agentic Task Synthesis for Generalization Tool Use", in ICML, 2026.

[2] J. Liu et al., "WebExplore and Evolve for Training Long-Horizon Web Agents", arXiv:2509.06501

합성 데이터를 생성 방향성


Task Synthetic부터 생성하는 합성 데이터 파이프라인 결정

- 최대한 실제와 비슷한 데이터들로 학습데이터를 만들고자 함
 - SKT에서 필요한 데이터는 **실제상황**을 반영한 **고난도 고품질** 데이터를 선호
- 특정 환경에서 발생한 이슈에 대한 대응능력도 학습
 - tool을 사용하여 이슈가 발생했을 때, **내부 요인** (e.g argument 잘못 사용) 혹은 **외부 요인** (e.g. rate limit)이 문제인지 이를 판단하고 다음 행동을 올바르게 수행하는 데이터도 필요

Tool-use 고품질 합성데이터 생성하면서 고민한 이슈

- LLM의 Reasoning 과정에서 발생한 Hallucination
 - LLM이 내부 지식을 이용해 추론하려는 경향이 강해 사실과 다른 Hallucination도 많이 발생
 - 상당한 Hallucination 발생하더라도 필요한 tool은 사용하며 작업 완료하는 상황 발생
 - 특정 환경에서 발생한 이슈에 대한 대응
 - 순간적으로 tool을 사용할 때 외부의 요인 (e.g. rate limit)이 발생할 때 이를 인지하고 다시 수행하는 데이터도 필요
-

- 최대한 LLM as Judge 전에 rule-based 필터링 진행
 - Ex) 문제를 해결하는 과정에서 사용해야 할 tool이 명확한 경우, Tool Match를 통해 필터링 진행
- 개방형 질문인 경우에도 명확히 평가할 수 있는 기준(Rubric 평가)을 가지고 필터링
- Hallucination이 잘 일어나는 분야(e.g 법률)에 대해서는 tool을 사용하는 매 turn마다 구체적인 검증을 진행하여 필터링



공헌 및 아쉬운 점

공헌

- 다양한 분야와 상황에서의 tool use를 사용하는 경우를 바탕으로 합성데이터를 만들어 Scale Diversity한 데이터 생성
 - 상황에 따라 발생할 수 있는 Case (e.g. 관련 데이터 찾을 수 없음)까지 합성데이터 구축
 - 한국어 관련 벤치마크는 많이 없지만, 한국에서 사용할만한 많은 MCP tools를 이용한 학습데이터 구축
- SFT로 인한 Hallucination이 생기는 것을 줄이기 위해 최대한 Hallucination에 대한 검증 과정을 도입함

아쉬운 점

- 고품질 데이터를 만드는 상황에서 필터링 된 양이 매우 많았음
 - 모든 필터링 과정을 통과한 최종 output이 10%~20% 정도
 - 'Self-improving 할 수 있는 방법이 없었을까?'하는 아쉬움이 큼
 - 직접 모델링을 통해 '해당 합성데이터가 어느정도 영향이 있었을까?' 확인하지 못함
-

Publications (Technical Report)

A.X K2 Technical Report

03 · PROJECT THREE

Naver Cloud, HyperCLOVA Foundation Model Research Intern

프로젝트 개요

2025.05.07 – 2025.10.31

프로젝트 목표

- 한국어, 영어, 수학, 코딩을 잘하는 LLM 백본 모델 만들기

담당 업무

- 대규모 고품질 사전학습 텍스트 (한국어, 영어, 수학, 코딩 등) 데이터 구축
 - ‘Context length generalization’ 일반화를 위한 효율적인 LLM 아키텍처 및 학습방법 탐구
 - 학습의 속도 효율성을 위한 분산 프레임 워크 탐구
-

합성 데이터

웹 데이터의 한계^[1]



- Web Data만 무작정 늘리는 것은 성능한계가 있음 (Data Wall)
- 꾸준히 정보 밀도가 높은 고품질 합성데이터의 필요성 증가
- Source Rephrasing Paradigm 접근방법으로 고품질 Scale-Diversity Synthetic Data를 만듦

수학, 코드 관련 다양한 합성 데이터 구축 전략

- Swallow Math/Code^[2] 방식 Rewriting
- Reverse Mathematical Reasoning^[3] 방식의 합성데이터
- Long CoT Rewriting

합성 데이터 관련 성과

- 32B LLM 적은 trade-off로 MMLU (5-shot) 성능 81점 달성 (79 → 81)
- 8B LLM의 GSM8k (5-shot) 84점 달성
- Standardized Benchmark와 관련 없는 전문적인 금융, 공학 지식을 합성데이터로 구축



prm 800k rewriting을 통한 고품질 데이터 생성

[1] Datology AI Team., "BeyondWeb: Lessons from Scaling Synthetic Data for Trillion-scale Pretraining", arxiv:2508.10975

[2] K. Fujii et al., "Rewriting Pre-training Data Boosts LLM Performance in Math and Code", arxiv:2505.02881

[3] P.Guo et al., "Exploring Reversal Mathematical Reasoning Ability for Large Language Models" in ACL, 2024.

대규모 클러스터를 이용한 합성데이터 생성시 병목 발생

목표


- Idle Cluster Node가 발생하면 해당 Clusters를 모두 잡아 합성 데이터 생성 파이프라인 개발

발생한 문제

- [warning] `Too many open files`

해결 과정

- 한 파일에 동시에 접근하는 Node수를 제한
- Ray 기반으로 클러스터 관리
 - Semaphore Concurrency 극대화해서 처리량 높이하고자 함



Quality Filtering을 위한 Scoring의 신뢰성

발생한 문제

- ‘A’ 모델로 Label Annotation 한 classifier 모델과 ‘B’ 모델로 Label Annotation한 classifier 모델의 Score 차이 발생


문제 분석

- ‘A’ 모델로 4점 이상의 점수를 받은 반면 ‘B’ 모델로 2점 이하의 점수를 받은 샘플들이 상당히 많음 (0.24%)
- ‘B’ 모델로 4점 이상인 점수를 받고, ‘A’ 모델로 2점 이하의 점수를 받은 샘플들은 비교적 적음 (0.0025%)

문제 원인

- ‘B’ 모델이 Prompt에 담겨있는 “초, 중학생에게 적합한 교육 콘텐츠”라는 내용 때문에 너무 어려운 내용이라 낮은 점수 제공

→LLM으로 데이터의 Quality를 평가할 때 LLM이 어느 부분에 집중을 하는지, 프롬프트에 대해 정밀한 분석을 할수록 원하는 방향으로 고품질 데이터 선별할 수 있다!



Long Context에서 노이즈 토큰을 제외한 Copying^[1](Rewriting) 실패

목표

- 한국어 article, paper 등 도메인 특화 Long Context 데이터에 [img]와 같은 학습에 필요 없는 토큰을 제거하고 고품질 학습 데이터 구축

Rewriting 필요 이유

- [그림] 혹은 저품질로 추출된 [표] 등, 데이터에 noise가 존재
- 해당 토큰만 제거했을 때 일부 context에서 문제가 생김
 - [그림] 참고했을 때... → 참고했을 때...
 - 하지만 [그림]을 Input으로 받지 않아도 내용 이해에 문제가 없는 데이터들이 많이 존재

발생한 문제

- 평균 60K정도 되는 데이터를 한번에 처리를 하고자 하면 프런티어 모델이라도 원하는 조건에 align된 output 생성 불가

해결 과정

- 데이터를 일정 범위의 Context 길이 범위 안에서 문단 단위로 Split
- System prompt 기반으로 해당 데이터의 내용을 최대한 보존하고 Copying 하면서 토큰 생성하도록 유도
- [표]에 대해서는 문제가 없는지 Rewriting 후에 Heuristic 하게 해당 데이터를 추출해서 LLM을 통해 판단

[1] M. Meyer et al., "How Many Different Outputs Can a Transformer Generate?" in ICML 2026.



Length Generalization를 위한 아키텍처 탐구

Motivation

- 기존 방법들로 Context Window를 확장하며 Long Context를 학습할 때 기존 벤치마크 성능 하락 확인
- Rotary Position Embedding (RoPE) 구조에서 발생하는 “Lost in the middle”^{[1],[2]} 개선
- Long Context 처리를 효율적으로 할 필요성

Research Direction

- 기존의 RoPE 단점을 보완하기 위해 일부 Layer 층에 Long Context에 대한 장점이 있는 Position Embedding 방식을 도입하여 Hybrid Position Embedding 방식으로 아키텍처 구성
- Long Context 처리를 효율적으로 하기 위해 KV Cache Compression 혹은 Selection 방식을 도입




Long Context에서 관련된 정보를 찾아 생성하는 능력 비교^[4]

[1] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” TACL, 2024.
[2] M. Ravaut et al., “On Context Utilization in Summarization with Large Language Models,” in ACL, 2024.
[3] Y. Chen et al., “HoPE: A Novel Position Encoding Without Long-Term Decay for Enhanced Context Awareness and Extrapolation,” in ACL, 2024.
[4] A. Kazemnejad et al., “The Impact of Positional Encoding on Length Generalization in Transformers,” in NeurIPS, 2023.

RNoPE 아키텍처 연구 (1/2)

실험 계획

- RoPE로 학습된 백본 모델에 RNoPE 구조로 변환 후, 벤치마크 측정 진행
- Context Window를 확장하는 Long Context 학습 단계부터 RNoPE 구조로 변환 후 학습 진행
- Sliding Window attention (SWA)을 사용하여 inference 속도 및 벤치마크 평가



RoPE 백본 모델을 RNoPE로 교체후 벤치마크 측정
Xinterval 의미는 x layer마다 NoPE 구조이며, 나머지는 RoPE 구조

model_name	mmlu@acc	piqa@acc	gsm8k_cot@exact_match,fl	humaneval@pass@1	mbpp@pass_at_1
OLMo-2-1124-7B	0.6285	0.8101	0.6740	0.1402	0.2300
olmo2-RNope-8interval	0.5964	0.8041	0.3654	0.1341	0.0020
olmo2-RNope-4interval	0.5729	0.7992	0.2699	0.1220	0.0000
Llama-3-8B	0.6543	0.7943	0.5451	0.3598	0.4800
Llama-3-8B-RNope-8interval	0.5775	0.7922	0.1046	0.2500	0.0080
Llama-3-8B-RNope-4interval	0.4210	0.7840	0.0485	0.1768	0.0140
SmoILM2-1.7B	0.5027	0.772	0.3071	0.0061	0.0214
SmoILM2-1.7B-RNope-8interval	0.4608	0.765	0.0599	0.0061	0
SmoILM2-1.7B-RNope-6interval	0.3835	0.7557	0.0318	0	0

RNoPE 아키텍처 연구 (2/2)

실험 결과

- Pretrained 된 LLM을 RNoPE 구조로 변환 하였을 때 지식의 망각이 발생
 - Normalization 과정이 많은 OLMO2 모델이 비교적 지식의 보존이 잘 됨
 - 지식보다 Reasoning 능력이 많이 떨어짐
- RNoPE 구조로 변환 후 학습을 진행할 때, 초기 적응 비용(Loss)이 존재하지만, 학습이 진행되면서 RoPE와 동일한 수준의 Loss로 수렴
- 하지만 벤치마크 평가는 조금씩 떨어졌고, CoT 능력은 충분히 회복하지 못함
- Context 길이가 커질수록 SWA 사용 유무에 따라 걸리는 시간의 차이가 기하급수적으로 커짐

Long Context 학습 후, 모델의 지식 및 추론 벤치마크 평가
학습을 하면서 안정적인 Loss 하락을 하였지만, 기존 성능을 따라잡는데 오래 걸리고, CoT로 추론하는 능력은 많이 부족

model_name	mmlu@acc	leaderboard_bbh	kmmlu_direct	global_mmlu_en	global_mmlu_ko	gsm8k_cot@fle	gsm8k@flexible	humaneval@pa	mbpp@pass_at
hcx-8B-stage2-72000	0.6612	0.4864	0.4912	0.7075	0.6075	0.6778	0.6937	0.6402	0.5972
hcx-8B-stage3-v2-1000 (YaRN)	0.6661	0.4784	0.5020	0.7200	0.6150	0.7005	0.6983	0.6280	0.6280
hcx-8B-stage3-rnope-swa-100	0.6344	0.4338	0.4478	0.6775	0.5475	0.4344	0.6308	0.5549	0.5220
hcx-8B-stage3-rnope-swa-200	0.6360	0.4376	0.4578	0.6950	0.5750	0.4041	0.6543	0.5976	0.5360
hcx-8B-stage3-rnope-swa-300	0.6419	0.4432	0.4649	0.6900	0.5850	0.1721	0.6634	0.6159	0.5440
hcx-8B-stage3-rnope-swa-400	0.6388	0.4466	0.4544	0.6925	0.5925	0.4966	0.6611	0.6098	0.5600
hcx-8B-stage3-rnope-swa-500	0.6440	0.4508	0.4670	0.6925	0.5825	0.1918	0.6550	0.5976	0.5700
hcx-8B-stage3-rnope-swa-600	0.6409	0.4524	0.4684	0.6950	0.5875	0.2123	0.6763	0.6220	0.5540
hcx-8B-stage3-rnope-swa-700	0.6479	0.4463	0.4756	0.7100	0.5875	0.2335	0.6550	0.6280	0.5460
hcx-8B-stage3-rnope-swa-800	0.6422	0.4419	0.4677	0.7075	0.5900	0.3351	0.6611	0.6341	0.5560
hcx-8B-stage3-rnope-swa-900	0.6449	0.4522	0.4756	0.7150	0.5850	0.1243	0.6649	0.6159	0.5520
hcx-8B-stage3-rnope-swa-1000	0.6449	0.4541	0.4788	0.7100	0.5950	0.3351	0.6748	0.6341	0.5520

HCX-8B (내부) 모델로 context token이 Forward 10번 통과하는데 걸리는 시간 비교
단위는 초(s)이며, 백본의 context window는 128K

model_name	10K	16K	32K	64K	128K
HCX-8B	7.41	15.67	37.67	103.69	328.77
HCX-8B-swa(8K)	7.3	15.12	31.99	71.82	175.33

Publications (Technical Report)

[arXiv:2601.03286](#)HyperCLOVA X 32B Think

[arXiv:2601.01792](#)HyperCLOVA X 8B Omni

[arXiv:2506.22403](#)HyperCLOVA X THINK Technical Report

04 · PROJECT FOUR

ACoRN: Noise-Robust Abstractive Compression in Retrieval-Augmented Language Models

International Joint Conference on Neural Networks (IJCNN), 2025


연구 개요

연구 배경

- Retrieval Augmented Generation (RAG)^[1]를 사용할 때, 프롬프트의 긴 텍스트로 인한 많은 연산비용 초래

연구 이슈

- 추상적 요약을 통한 압축 방식^[2]이 쿼리와 관련된 내용을 놓치는 문제 발생
 - 관련이 없거나 잘못된 정보에 대한 높은 가중치로 쿼리의 답변에 도움이 되는 정보를 놓치게 됨 (attention dilution)
 - Long Context에서 Position Bias(“Lost in the Middle”)문제가 발생하여 위치에 따라 관련 내용을 놓치는 경우가 많음




[1] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," in NeurIPS, 2020.
[2] F. Xu, W. Shi, and E. Choi, "RECOMP: Improving Retrieval-Augmented LMs with Compression and Selective Augmentation," in ICLR, 2024.

Retrieval Documents 분석

Classifying Retrieved Document

- Retrieved Document 단위로 추상적 요약 대상 문서를 선정했을 때 LLM 성능에 미치는 영향 분석
- Heuristic하게 도움이 되는 문서와 방해가 되는 문서 구분
 - 정답 문자열을 포함한 문서들을 정답에 대한 직접적인 정보를 줄 수 있는 후보군으로 생각하여 Evidential Document로 정의
 - Evidential Document가 아닌 문서들을 2가지로 구분
 - 쿼리의 답변에 관련이 없는 정보로만 구성된 문서 (Irrelevant Document)
 - 쿼리의 답변에 잘못된 답변을 유도하는 정보가 담긴 문서 (Factual Error Document)



Flan-T5로 Retrieved Documents를 추상적 압축하여 LLM(LLAMA-3.1-8B-Instruct)에 전달했을 때 EM-score 비교

ACORN: Noise-Robust Abstractive Compression in Retrieval-Augmented Language Models


Method

학습 데이터 구축

- 쿼리를 통해 얻은 Retrieved Documents에서 Evidential Documents만 LLM (Teacher model)에 전달하여 Summarization label 생성

Supervised Fine-tuning(SFT)

- Summarization La



제시한 방법의 학습 프로세스

Experiments & Results (1/2)

기존 Open-Domain Question Answering (ODQA) 벤치마크에서 우수한 성능

- 압축 전 대비 높은 질의응답 정확도 (EM↑)
- 핵심 정보만 유지하여 높은 압축 효율 (CR↓)
 - $CR = \frac{\# \text{ Compressed Tokens}}{\# \text{ Retrieved Document Tokens}}$
- LLM에 전달되는 입력 길이 감소로 추론 시간 단축 (Inference Time↓)

Natural Questions, TriviaQA, PopQA 데이터셋에서 결과

Method	NQ				TriviaQA				PopQA			
	EM (↑)	F1(↑)	CR(↓)	Inference Time(↓)	EM (↑)	F1(↑)	CR(↓)	Inference Time(↓)	EM (↑)	F1(↑)	CR(↓)	Inference Time(↓)
No Retrieval	19.94	31.46	-	0.249	49.65	59.59	-	0.162	20.51	23.68	-	0.132
Top-1 document	27.87	42.12	-	0.241	48.21	61.67	-	0.216	17.87	21.01	-	0.154
Top-5 documents	31.83	47.40	-	0.444	57.90	69.38	-	0.246	41.46	51.02	-	0.321
LongLLMLingua [22]	26.84	42.72	0.562	0.396	54.45	66.59	0.562	0.297	38.24	47.87	0.597	0.238
Quito [38]	29.94	44.04	0.484	0.316	56.61	67.61	0.484	0.258	41.89	50.36	0.523	0.241
RECOMP [12]	32.58	45.42	0.052	0.225	58.64	68.40	0.049	0.174	-	-	-	-
ACoRN (T5-large)	34.97	47.70	0.064	0.205	58.20	68.33	0.049	0.174	45.60	52.38	0.059	0.137
Flan-T5-large [29]	31.97	45.15	0.133	0.227	57.34	67.72	0.085	0.183	42.89	48.80	0.071	0.142
ACoRN (Flan-T5-large)	35.56	48.48	0.065	0.208	58.33	68.58	0.056	0.174	45.75	52.82	0.062	0.139

Experiments & Results (2/2)

Noise가 많은 Documents에서 Evaluation 진행

- 세밀하게 Noise를 분류하고 반영한 Training Dataset으로 학습했을 때 Noisy Retrieval 환경 (Real-World)에서 성능 저하 최소화

키워드 손실률 완화

- 기존 추상적 압축 방법(RECOMP)보다 높은 정답 문자열 보존율(Preserving Answer String Ratio, PAR)을 기록
 - $PAR = \frac{\# (Compressed\ Outputs\ containing\ the\ Answer\ String)}{\# (Queries\ with\ at\ least\ one\ Evidential\ Document)}$
- 다른 압축 방법인 Extractive Compression (Token-pruning)과 비슷한 보존율을 기록하기도 함
 - LongLLMLingua^[1] : Perplexity 기반 Token Importance를 이용해 중요도가 낮은 토큰들을 제거

여러 종류의 Noise 정보를 삽입한 Natural Questions, TriviaQA, PopQA 데이터셋에서 결과

Method	NQ		TriviaQA		PopQA	
	EM (↑)	F1 (↑)	EM (↑)	F1 (↑)	EM (↑)	F1 (↑)
ACoRN (T5-large)	34.79 → 32.68 (-2.11)	47.70 → 45.59 (-2.11)	58.20 → 57.31 (-0.89)	68.33 → 67.35 (-0.98)	45.60 → 44.39 (-1.21)	52.38 → 50.67 (-1.71)
w/o noise documents augmentation	35.15 → 32.54 (-2.61)	47.65 → 44.88 (-2.77)	58.57 → 57.38 (-1.19)	68.54 → 67.23 (-1.31)	44.10 → 41.82 (-2.28)	50.37 → 47.88 (-2.49)

여러 종류의 Noise 정보를 삽입한 Natural Questions, TriviaQA, PopQA 데이터셋에서 압축률(CR) 및 정답 문자열 보존율(PAR)

Method	NQ		TriviaQA		PopQA	
	CR(↓)	PAR(↑)	CR(↓)	PAR(↑)	CR(↓)	PAR(↑)
<i>Token pruning</i>						
LongLLMLingua	0.5607	0.6320	0.5625	0.7044	0.5963	0.7760
<i>Abstractive compression</i>						
RECOMP	0.0557	0.4966	0.0522	0.6283	-	-
ACoRN (T5-large)	0.0637	0.6425	0.0522	0.6380	0.0675	0.7521
ACoRN (Flan-T5-large)	0.0663	0.6687	0.0579	0.6686	0.0674	0.7635

[1] H. Jiang et al., "LongLLMLingua: Accelerating and Enhancing LLMs in Long Context Scenarios via Prompt Compression," in ACL, 2024.

공헌 및 한계점

공헌 (Contributions)

- Fine-grained Retrieval Noise를 고려한 Robust Abstractive Compression 제안
 - Noise-aware Training을 통해 Retrieval Noise에 대한 Robust 향상
- Evidential Documents 기반 Summarization Label의 효과성을 입증
- 기존 방법 대비 핵심 정보 보존 및 ODQA 성능 향상

한계 (Limitations)

- Evidential Documents를 Answer String 기반으로 정의하는 Heuristic 방법에 의존
 - Multi-hop/Multi-document Reasoning 환경으로의 확장성은 미검증
-

05 • PROJECT FIVE

AI Assistant for elementary teachers using Large Language Models

[i-scream edu] Industry-Academia Research Project

프로젝트 개요


2023.09~2024.01

연구 목표

- 초거대 언어모델을 기반으로 교사의 질문에 초등 교과 과정을 기준으로 답변을 하는 어시스턴트 개발

연구 요약




- 초등 교과 교육 과정에 대한 지식 학습
 - 공개된 언어 모델에 부족한 한국어 초등 교과 과정에 대한 지식 학습
- 초등 교육 교사의 질문에 대해 초등 교과 과정 내용을 기준으로 답변
- 사용자가 임의로 입력한 내용을 기반으로 한 문제 생성



개발 프레임워크

모델 학습

- Poly-ko-12.8^[1] 을 Base Model로 학습
 - 추론 능력은 비교적 부족하였지만 한국적 사고가 가장 강한 모델이라 판단
- 도메인 적응 사전학습(Domain Adaptive Pre-training, DAPT)^[2]
 - 백본 모델의 사전학습에서 학습되지 않은 교과서 지식 주입
- 지시 기반 학습 (Instruction-following tuning)
 - 사용자의 지시에 따른 응답을 생성하기 위해 지시 데이터에 미세조정
 - NEFTune^[3] 기법을 활용하여 noise 강건성 향상



[1] H. Ko et al., "A Technical Report for Polyglot-Ko: Open-Source Large Scale Korean Language Models," arXiv:2306.02254

[2] S. Gururangan et al., "Don't Stop Pretraining: Adapt Language Models to Domain and Tasks," in ACL, 2020.

[3] N. Jain et al., "NEFTune: Noisy Embedding Improve Instruction Finetuning," in ICLR, 2024.

사전학습 데이터셋

사전 학습 데이터셋 구성

- 다양한 교과서 및 참고서 등이 포함되어 있는 제공된 평문텍스트 기반 데이터베이스 활용
 - 초거대 언어 모델의 사전 지식 학습에 사용할 텍스트 데이터셋을 구축
 - 문단 단위 혹은 대문항 단위로 데이터 구분
- 초등 교과 과정 지식을 기반으로 사전 학습 데이터 정제
 - 초등학교 학년, 과목, 단원 등을 조건화해 지식 학습

제목: 자전거 타기 성공. 오랜만에 날씨가 화창했다. 현관에 세워 놓은 자전거가 보였다. 어머니께서 내 마음을 아셨나 보다. 나는 어머니를 바라보며 기운차게 말했다.\n“오늘은 꼭 성공할 거예요!”\n어머니께서는 웃으며 고개를 끄덕이셨다. 점심을 먹은 뒤에 어머니와 함께 놀이터로 나갔다.\n... \n국어 과목, 2학년 1학기,
1단원:[단원명]
3. 나눗셈식을 이용하여 15의 약수를 알아봅시다. 1) 15의 약수를 모두 찾아보세요. \$15\$ [빈칸] = 15\$ \n ... \$15 / [빈칸] = 1\$ \n 15의 약수를 작은 수부터 모두 써 보세요. \n ... \n 수학 과목, 3학년 2학기, 2단원:[나눗셈]


지시 기반 데이터셋

지시 기반 학습 데이터셋 구성

- 질의 응답, 문제 생성 등 복합적인 작업 능력 향상을 위한 지시 기반 미세 조정^[1]
 - 초거대 언어 모델이 지시에 대한 응답을 생성하도록 미세 조정하여 사용자와 상호 작용 능력 향상

외부 데이터를 활용한 교차 시스템 프롬프트

- 공개된 한국어 지시 데이터셋을 활용해 다양한 지시에 대한 작업 능력 향상
- 초등교육 언어 모델의 perplexity를 기준으로 초등 교과 과정 지식 범위 외의 지시 혹은 응답 제한



[1] L. Ouyang et al., "Training language models to follow instructions with human feedback," in Proceedings of Advances in Neural Information Processing Systems (NeurIPS), 2022.


데이터셋

데이터셋 구성


- OCR로 인한 일부 망가진 교과서 문서를 LLM을 활용해 Rewriting 및 filtering으로 문서 정제
 - 수학 같은 경우 '/'과 같이 분수를 나타내거나 나눗셈을 할 때 사용하는 기호가 많이 생략됨
 - 당시에는 문제 데이터가 어렵지 않았기 때문에 보면서 최대한 filtering 진행하기도 함

데이터셋 구성

- DAPT 데이터 (57,129)
 - 정제된 교과서 데이터: 3,325
 - 네이버 웹 크롤링 데이터: 21,280
 - 교육 관련 도서 데이터: 32,524
- 지시 학습 데이터 (58,143)
 - 일반 도메인 데이터: 41,850
 - 교육 도메인 데이터: 16,293



DAPT 데이터 셋 구성 비율



지시 데이터 구성 비율


문제 풀이 성능 평가

주관식 문제 풀이 능력 평가

- BLEU (Bilingual Evaluation Understudy) Score^[1] 기반의 모델의 주관식 정답 생성 능력 평가
 - 최적 정답과 생성 응답 사이의 겹치는 정도를 문장의 길이와 단어의 중복 정도를 고려하여 기반으로 모델이 생성한 정답의 정확도 분석
- BERT (Bidirectional Encoder Representations from Transformer) Score^[2] 기반의 모델의 주관식 정답 생성 성능 평가
 - 최적 정답과 생성 응답의 문맥을 고려한 임베딩의 코사인 유사도를 통해 정밀도와 재현율을 측정
 - 생성 응답이 내재하고 있는 의미와 통사 구조의 다양성 평가

객관식 문제 풀이 능력 평가

- 문맥, 문제, 보기를 모델에 입력하고 모델이 생성한 정답에 대한 정확도 평가
 - 다중 선택 QA (Multiple Choice QA) 작업의 입력 포맷을 활용
 - 보기 선택에 따른 정확도 평가



[1] K. Papineni et al., "BLEU: a method for automatic evaluation of machine translation," ACL, 2002.

[2] T. Zhang et al., "BERTScore: Evaluating Text Generation with BERT," arxiv, 1904.09675

성능 평가

사용자 만족도 평가

- 지시에 대한 응답의 사용자 평가 (1~4점 기준)
 - 평가를 위해 다양한 수행 작업에 대한 테스트 지시 데이터 생성
 - 테스트 데이터셋의 지시에 대해 모델 응답을 생성하고, 사용자들이 정의된 기준에 따라 생성된 응답을 평가

모델 수행 능력 평가

- 주요과목 문제해결 뿐만 아니라 행정 업무와 관련된 응답도 잘 수행

"아래 내용을 참고하여 학부모 총회 안내문을 작성해줘. 300자 이내

일시: 2023년 6월 20일 (목요일) 오후 7시
장소: 학교 다목적 홀

총회 주제:
학교의 교육과정 및 교육 방침 소개
교사진과 학교 운영진 소개
학교 시설 및 교육 자원 소개
학부모 자원봉사 및 협력 방안 논의"

제목: 우리 학교의 교육과정 및 교육 방침 소개

안녕하십니까? 우리 학교는 부산광역시에 위치한 40여 년의 전통을 가진 우수한 학교입니다. 우리 학교는 학생들의 교육을 위해 최선을 다하고 있으며, 아
우리 학교의 교육과정과 교육 방침을 소개합니다.

1. 교육과정:

 - 학년별 연간 교육과정 및 교육 내용:
 - 학년별 교과 수업 시간:
 - 학년별 제철 학습 및 현장 학습:
 - 학년별 평가 방법:
 - 학년별 자율 학습 및 방과 후 학습:
 - 방과 후 학교 프로그램:
 - 보충 학습 관리 시스템:
 - 학교생활기록부:

2. 교육 방침:

 - 학년별 교육 목표:
 - 학생들의 창의적, 인성적, 성직적 발달을 위한 교육 과정:
 - 학생들의 참여와 주도를 유도하는 교육 방법:
 - 학생들의 건강과 안전을 보장하는 교육 환경:
 - 학생들의 성취감과 자존감을 높이는 교육 시스템:
 - 학생들의 가족과 지역사회와의 협력:
3. 학부모 자원봉사:

 - 학부모 자원봉사 교육:
 - 학부모 자원봉사 제도:
 - 학교 교육 활동 참여 기회:
 - 학교 교육 활동 지원 및 참여:
 - 학부모와 학교 간의 소통 및 신뢰 구축:

4. 학교 운영진 소개:


 - 학교 운영위원회:
 - 학교 운영진:
 - 통학 버스 운영진:

학교 생활에 관련하여 준비해야 할 사항에는 다음과 같은 것들이 있습니다.

 - 옷차림: 간편한 복장으로 참석해 주시면 됩니다.
 - 필기도구: 행사 자료를 참고하시면 됩니다.
 - 선물: 학생들의 감사의 마음을 담아 선물을 준비하시면 좋습니다. (ex: 학용품, 쿠키, 과일 등)

감사합니다.

안내문 생성 능력



06 • PROJECT SIX

AI Agents for CBRN Operational Command and Guidance

[Agency for Defense Development (ADD)] National R&D Project

프로젝트 개요

2023.09~2023.11 (과제 제안서 작성), 2024.12~2025.05 (프로젝트 수행)



연구 목표

- 실시간 화생방 탐지 정보를 기반으로 분석하고 의사결정 및 정보를 제공해줄 수 있는 언어모델 기반 에이전트 개발

연구 요약

- 실시간 화생방 탐지 정보를 기반으로 상황을 분석하고 의사결정 정보를 제공하는 에이전트 프레임워크 개발
- 온프레미스 환경에서 효율적인 서빙 프레임워크 검토
- React + Node.js기반 demo 제작하여 Retrieval, NBC-RAMPS 실시간 탐지 기록 활용 흐름 시각화

특수 도메인을 고려한 온프레미스 방식의 대규모 언어 모델링 및 추론 연구



화생방 관련 실시간 정보를
제공해주는 에이전트


프레임워크

연구 중요한 점

- 빠른 토큰 생성이 필수요소이며 TTFT(Time To First Token)이 평가 사항

프레임 워크 구조

- AutoAct^[1] 를 참고해서 기본 Baseline 구축
- 쿼리를 받았을 때 단순 전문 지식이면 화생방 교범, 교리를 Retrieve, 실시간 정보가 필요한 경우 해당 관련 tool을 사용해서 정보를 받는 구조



[1] S. Qiao et al., "AutoAct: Automatic Agent Learning from Scratch for QA via Self-Planning," in ACL, 2024.